

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«Национальный исследовательский университет
«Высшая школа экономики»

ФАКУЛЬТЕТ МАТЕМАТИКИ

Шишлевская Валерия Васильевна

**Модели конфигурации сети сообществ в
политических и новостных Telegram-каналах до и
после СВО с применением тематического
моделирования и методов сетевого анализа**

Выпускная квалификационная работа — бакалаврская работа
по направлению подготовки 01.03.01 — Математика,
образовательная программа «Математика»

Рецензент:

Кандидат политических наук,
доцент
Беленков Вадим Евгеньевич

Научный руководитель:

Кандидат политических наук
преподаватель
Синицина Арина Викторовна

Москва 2025

1 Аннотация.

В своей дипломной работе я анализирую выборку данных из политических и новостных Telegram-каналов до и после начала СВО (Специальной военной операции). Цель работы — выявить, как изменилась конфигурация сетей политических и новостных Telegram-сообществ, а также направленность аффективной поляризации и тональность сообщений в указанных временных периодах. Для отслеживания изменений планируется использовать следующие методы: сетевой анализ (включая расчёт модулярности и алгоритм Лувена), методы машинного обучения для выделения ключевых идеологий, а также сентимент-анализ для определения эмоциональной окраски сообщений. Ожидается, что исследование позволит зафиксировать тематические и структурные сдвиги в медиапространстве, выявить устойчивые сообщества и ключевые объекты политической враждебности.

2 Введение.

Нельзя отрицать, что человек, как часть огромного сообщества, является социальным существом. И для отдельного индивида важнее не столько его уникальный набор качеств, сколько принадлежность к определенному сообществу. Например: социальному, экономическому или культурному. Таким образом, все люди отождествляют себя с тем или иным сообществом. И в дальнейшем, защищая идеи и целостность своей группы, возникают разногласия с представителями других групп. Одним из явных примеров такого противостояния — это приверженность к определенной политической идеологии. Определим ключевые понятия:

Политическая поляризация — это процесс усиления различий между гражданами по вопросам политики, идеологии и ценностей, в результате чего формируются противоположные и малосовместимые политические лагеря. Она может проявляться как на уровне политических элит, так и среди массовой публики, приводя к резкому расхождению мнений и снижению готовности к компромиссу.

Аффективная поляризация — это форма поляризации, при которой участники политического процесса начинают испытывать не просто несогласие с представителями другой партии, но явную антипатию, недоверие и враждебность к ним. Это эмоциональное измерение поляризации, выражющееся, например, в отказе от общения, сотрудничества или даже межличностных контактов с оппонентами, независимо от содержания их взглядов. При аффективном типе поляризации у индивида формируется отношение "свой-чужой" относительно членов одного сообщества и неприязнь к другому члену сообщества, что зависит только от его принадлежности к определенной политической идеологии и не зависит от каких-либо иных факторов.

3 Постановка задачи.

В исследованиях [Huddy2005] и [Margalit2013], показано, что в условиях угрозы безопасности и военных конфликтов в обществе усиливаются консервативные, националистические и патриотические настроения. Поэтому начало СВО, которое я беру в качестве точки перелома, вполне может служить основой для анализа подобных из-

менений. Меня интересует, проявится ли этот тренд и в русскоязычных сообществах, особенно в российском контексте. Большинство подобных исследований ранее проводились в Европе и США, где акцент делается на противопоставлении «левых» и «правых», что затрудняет прямое перенесение их выводов на российскую реальность.

Говоря про Россию, принято выделять следующие три идеологии [Solovyev2025]: консервативная, либеральная, коммунистическая. Опишу кратко основные ценности каждой из них.

Либеральная идеология:

Свобода личности, защита прав человека, индивидуальные права, терпимость к различиям, поддержка социальных реформ, минимальное вмешательство государства в экономику.

Консервативная идеология:

Приверженность традициям, стабильность, порядок, национальная идентичность, патриотизм, защита семьи и религиозных норм, скепсис к резким социальным изменениям.

Коммунистическая идеология:

Равенство всех людей, борьба против социального неравенства и эксплуатации, отказ от частной собственности на средства производства, сильная роль государства в экономике, интернационализм.

4 Методы измерения аффективной поляризации.

В современной политической науке для изучения аффективной поляризации используются различные подходы. Наиболее распространёнными являются три группы методов: *опросные*, *имплицитные* и *поведенческие*. В рамках данного исследования используется альтернативный подход — *анализ сообщений в цифровой среде (Telegram)*.

4.1 Опросные методы.

Опросные методы предполагают получение прямых ответов от респондентов о своём отношении к представителям различных политических групп.

Примеры:

- *Feeling thermometer*: респондента просят оценить свою симпатию к своей партии и к оппозиционной по шкале от 0 (очень холодное отношение) до 100 (очень тёплое отношение). Разность этих оценок интерпретируется как уровень аффективной поляризации.
- *Вопросы о социальной дистанции*: готовы ли респонденты, например, вступить в брак с человеком противоположных политических взглядов, жить с ним по соседству или работать в одной команде.

Преимущества: простота реализации, широкая распространённость.

Недостатки: эффект социальной желательности, ограничение спектра эмоций.

4.2 Имплицитные методы.

Имплицитные методы направлены на выявление неосознанных или скрытых установок, которые респонденты не всегда готовы выразить открыто.

Пример: *Имплицитный Ассоциативный Тест (IAT)* — участнику показываются стимулы (например, слова 'демократ', 'республиканец', 'хороший', 'плохой') и он должен как можно быстрее классифицировать их. Более быстрая реакция при сочетании "своя партия — хорошее" и медленная при "чужая партия — хорошее" сигнализируют о наличии скрытой симпатии или антипатии.

Преимущества: позволяет выявить глубинные установки, неискажённые сознательным контролем.

Недостатки: требует лабораторных условий, чувствителен к внешним факторам.

4.3 Поведенческие индикаторы.

Поведенческие методы фокусируются на реальном выборе респондентов в контексте политической принадлежности.

Примеры:

- Люди с большей вероятностью покупают товар, зная, что он ассоциирован со "своей" партией.
- Участники эксперимента чаще нанимают на работу человека с совпадающими политическими взглядами, даже если другой кандидат более квалифицирован.
- В экспериментах знакомств профили с указанием партийной принадлежности получают больше откликов от сторонников той же партии.

Преимущества: высокая валидность, измерение реального поведения.

Недостатки: трудозатратность, необходимость точной постановки эксперимента.

4.4 Анализ Telegram-сообщений

В данной работе применяется альтернативный метод оценки уровня аффективной поляризации — анализ сообщений из политических и новостных Telegram-каналов. В отличие от описанных выше опросных и экспериментальных стратегий, этот подход основывается не на смоделированных условиях или ответах респондентов, а на естественно возникающих данных.

Методы, рассмотренные выше, имеют существенные недостатки:

- могут ограничивать диапазон эмоциональной реакции.
- присутствует риск социальной желательности ответов.

Telegram, в свою очередь, предоставляет среду, где пользователи анонимно выражают мнение, зачастую без страха последствий и без внешней модерации. Это делает платформу особенно ценной для анализа именно аффективной поляризации, так как:

- позволяет наблюдать органическую форму враждебности к оппонентам;
- даёт возможность зафиксировать язык, используемый для выражения «чужих» и «своих»;
- отражает аффективную динамику на фоне реальных политических событий.

Примеры лексики, отражающей аффективную поляризацию в Telegram

Тип выражения	Пример (адаптировано)	Интерпретация
Дегуманизация оппонента	«Эти либероиды вообще не думают головой»	Пренебрежительная лексика по отношению к чужой группе
Контраст «мы — они»	«У нас — здравый смысл, у них — фанатизм»	Подчёркивание морального превосходства своей группы
Насмешка/ирония	«Ну конечно, они опять за «ценности» — смешно!»	Эмоциональная дискредитация противоположной позиции
Обобщения	«Все эти патриоты одинаково зомбированы»	Стереотипизация членов другой группы
Выраженная эмоциональность	«Я ненавижу этих продажных журналистов, они разрушают страну»	Яркое эмоциональное окрашивание
Навешивание ярлыков	«Типичный ватник / типичный либерал»	Обозначение оппонента стереотипной категорией

Таблица 1: Примеры аффективной лексики в Telegram-среде

Таким образом, анализ сообщений Telegram-каналов позволяет получить репрезентативную выборку спонтанных высказываний, в которых отражаются ключевые аспекты межгрупповой аффективной поляризации.

5 Методы.

5.1 Сетевой анализ и его значение в политических исследованиях.

Сетевой анализ представляет собой междисциплинарный метод исследования, позволяющий выявлять структуру и характер взаимодействий между элементами системы. В контексте политической коммуникации узлами графа могут выступать как отдельные участники (пользователи, лидеры мнений), так и коллективные субъекты — например, Telegram-каналы. Связи между ними могут формироваться на основе репостов, упоминаний, тематических пересечений или общей аудитории.

Одним из ключевых понятий сетевого анализа является *сообщество* — группа узлов, между которыми связи плотнее, чем с остальной частью графа. Такие сообщества

часто совпадают с идеологическими кластерами, объединёнными сходством позиций, тональностью и общей политической повесткой. Изучение конфигурации таких сообществ позволяет не только картировать информационное поле, но и выявлять процессы радикализации, изоляции и аффективной поляризации.

Особую роль играет анализ динамики сетевой структуры. Сравнение графов, построенных по данным из разных временных периодов, даёт возможность наблюдать за тем, как перераспределяются связи, какие каналы приобретают центральное положение, а какие выпадают из активной дискуссии. В условиях политической нестабильности это особенно важно для отслеживания изменений в публичной сфере.

Таким образом, сетевой анализ позволяет перейти от линейной оценки контента к изучению *структур коммуникаций*, что особенно ценно в условиях сложных и фрагментированных медиасред, таких как Telegram. Он даёт возможность выявлять неочевидные зависимости, отслеживать консолидацию или фрагментацию идеологических лагерей и количественно оценивать глубину их изоляции друг от друга. Посмотрим на метрики и инструменты, позволяющие этого добиться.

5.2 Модулярность.

Модулярность — это метрика, оптимизируемая при разбиении графа на сообщества, и определяемая как значение в диапазоне от -1 до 1 . Она измеряет, насколько плотными являются связи внутри сообществ по сравнению с ожидаемым случайным распределением связей.

Для взвешенного графа модулярность вычисляется по формуле:

$$Q = \frac{1}{2m} \sum_{i=1}^N \sum_{j=1}^N \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j),$$

где:

- A_{ij} — вес ребра между вершинами i и j ;
- k_i, k_j — суммы весов рёбер, инцидентных вершинам i и j ;
- m — сумма всех весов рёбер в графе;
- N — общее число вершин;
- c_i, c_j — сообщества, к которым принадлежат i и j ;
- $\delta(c_i, c_j) = 1$, если $c_i = c_j$, и 0 в противном случае (функция Кронекера).

Для отдельного сообщества c можно вычислить вклад в общую модулярность по формуле:

$$Q_c = \frac{1}{2m} \sum_{i,j} A_{ij} \cdot \mathbf{1}\{c_i = c_j = c\} - \left(\sum_i \frac{k_i}{2m} \cdot \mathbf{1}\{c_i = c\} \right)^2$$

или в компактной форме:

$$Q_c = \frac{\Sigma_{\text{in}}}{2m} - \left(\frac{\Sigma_{\text{tot}}}{2m} \right)^2,$$

где:

- Σ_{in} — сумма весов рёбер внутри сообщества c ;
- Σ_{tot} — сумма весов всех рёбер, инцидентных вершинам сообщества c .

Общая модулярность:

$$Q = \sum_c Q_c$$

5.3 Алгоритм Лувена: поэтапное описание.

1. **Инициализация:** каждая вершина графа считается отдельным сообществом.
 2. **Локальная оптимизация:** для каждой вершины i проверяются соседние сообщества. Для каждого такого сообщества C_j оценивается прирост модулярности:
- $$\Delta Q = Q_{\text{new}} - Q_{\text{old}}$$
- при перемещении вершины i в C_j . Если $\Delta Q > 0$, перемещение совершается.
3. **Повтор:** процесс продолжается, пока не останется вершин, для которых возможно улучшение модулярности.
 4. **Сжатие графа:** каждое найденное сообщество сворачивается в одну вершину; веса рёбер между новыми вершинами равны суммарным весам между соответствующими сообществами.
 5. **Рекурсия:** алгоритм применяется к новому графу. Повторяется, пока модулярность перестаёт увеличиваться.

Таким образом, алгоритм Лувена позволяет эффективно приближённо максимизировать модулярность в больших графах за разумное время, выявляя устойчивую иерархическую структуру сообществ.

5.4 Постановка задачи сентимент-анализа.

Пусть X — множество русскоязычных сообщений Telegram-каналов, а $Y = \{-1, 0, +1\}$ — множество меток полярности (*Negative*, *Neutral*, *Positive* соответственно). Требуется построить отображение

$$f_\theta : X \longrightarrow Y,$$

аппроксимирующее условные вероятности $P(y \mid x; \theta)$, где θ — параметры модели. Задача относится к обучению с учителем (multiclass classification) и решается путём минимизации усреднённой кросс-энтропии:

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^3 y_{ik} \log p_{ik}, \quad p_{ik} = P_\theta(y = k \mid x_i).$$

5.5 Архитектура модели RuBERT

Для решения задачи используется предобученная модель `blanchefort/rubert-base-cased-sentiment`, представляющая собой русскоязычную версию BERT (Transformer-Encoder). Её основные компоненты следующие.

Токенизация. Текст x разбивается алгоритмом BPE на (t_1, \dots, t_L) , $L \leq 512$. Каждому токену сопоставляется эмбеддинг $E(t_i) \in \mathbb{R}^d$; к нему добавляется позиционный вектор P_i , образуя матрицу $H^{(0)} \in \mathbb{R}^{L \times d}$.

Механизм самовнимания. В каждом из N слоёв Encoder'a применяется много-головое самовнимание (multihead attention):

$$\text{head}_j = \text{softmax}\left(\frac{Q_j K_j^\top}{\sqrt{d_k}}\right) V_j, \quad Q_j = H^{(l)} W_j^Q, \quad K_j = H^{(l)} W_j^K, \quad V_j = H^{(l)} W_j^V.$$

Результаты h голов конкатенируются и умножаются на W^O , после чего применяется остаточная связь и LayerNorm.

Feed-Forward слой. Каждый токен проходит двухслойный FFN(x) = $\sigma(xW_1 + b_1)W_2 + b_2$ с нелинейностью GELU.

Классификатор. После N слоёв берётся вектор $\mathbf{h} = H_{[\text{CLS}]}^{(N)} \in \mathbb{R}^d$, к которому применяется линейное преобразование $\mathbf{z} = W\mathbf{h} + b$ и softmax. Обучение модели на корпусе сентимент-разметки выполнялось авторами датасета; в данной работе используется только *инференс* (вычисление p_{ik}), поэтому градиенты не требуются (`torch.no_grad()`).

5.6 Стратегия переноса обучения

Используется *transfer learning*.

- 1 **Предобучение** (pre-training): RuBERT обучался на неразмеченном корпусе по задаче Masked Language Modeling.
- 2 **Донастройка** (fine-tuning): поверх BERT добавлен линейный классификатор и модель дообучена на размеченных твитах/отзывах

Это позволяет использовать богатое языковое представление при отсутствии собственного большого датасета.

5.7 Алгоритм инференса

Для набора текстов $\{x_i\}_{i=1}^N$ инференс выполняется батчами размера $B = 8$:

1. токенизация и паддинг до $L \leq 512$;
2. передача батча в GPU/CPU;

3. вычисление логитов \mathbf{z}_i и вероятностей $\mathbf{p}_i = \text{softmax}(\mathbf{z}_i)$;
4. определение метки $\hat{y}_i = \arg \max_k p_{ik}$;
5. сохранение результата в датафрейм.

6 Классификация идеологий сообщений

6.1 Формальная постановка

Рассматривается множество сообщений X и конечный класс идеологий $Y = \{\text{консервативная, либеральная, коммунистическая}\}$. Необходимо построить отображение

$$g : X \longrightarrow Y,$$

определенное без дополнительного обучения (*zero-shot classification*) на основе векторных представлений $\phi : X \rightarrow \mathbb{R}^d$, полученных моделью Sentence-BERT [?]. Класс сообщения x выбирается как

$$\hat{y} = \underset{k \in \{1, 2, 3\}}{\operatorname{argmax}} \operatorname{sim}(\phi(x), c_k),$$

где c_k — векторное представление k -й идеологии, а sim — косинусная близость.

6.2 Получение векторных представлений категорий

Для каждой идеологии задан словарь ключевых слов/фраз $\mathcal{V}_k = \{w_{k1}, \dots, w_{kn_k}\}$. Составляется псевдодокумент $s_k = w_{k1} w_{k2} \dots w_{kn_k}$, после чего вычисляется

$$c_k := \phi(s_k) \in \mathbb{R}^d.$$

Тем самым каждому классу соответствует единичный вектор-эмбеддинг, описывающий его «идеологическое пространство».

6.3 Sentence-BERT и модель MiniLM

Используется публикационная модель `paraphrase-multilingual-MiniLM-L12-v2` (12 слоёв, ширина $d = 384$), которая дообучена по задаче contrastive learning с функцией потерь

$$\mathcal{L}_{\text{NT-Xent}} = -\log \frac{\exp(\operatorname{sim}(\phi(x_i), \phi(x_j))/\tau)}{\sum_{k \neq i} \exp(\operatorname{sim}(\phi(x_i), \phi(x_k))/\tau)},$$

где (x_i, x_j) — пара парофраз, а τ — параметр температуры. Такое обучение заставляет модель располагать семантически схожие предложения ближе в \mathbb{R}^d .

6.4 Косинусная близость и правило решения

Для двух векторов $u, v \in \mathbb{R}^d$,

$$\operatorname{sim}(u, v) = \frac{\langle u, v \rangle}{\|u\|_2 \|v\|_2}, \quad -1 \leq \operatorname{sim}(u, v) \leq 1.$$

Так как все векторы нормируются, решающее правило эквивалентно максимизации скалярного произведения, что переводит задачу в *nearest-centroid classification* при метрике косинусной близости.

6.5 Алгоритм инференса

Для батча сообщений $\{x_i\}_{i=1}^B$:

1. **Эмбеддинг:** вычислить $E = [\phi(x_1); \dots; \phi(x_B)] \in \mathbb{R}^{B \times d}$;
2. **Сходства:** $S = E C^\top$, где $C = [c_1; c_2; c_3] \in \mathbb{R}^{3 \times d}$;
3. **Выбор класса:** $\hat{y}_i = \arg \max_k S_{ik}$;
4. **Объединение** результатов в столбец `topic` датафрейма.

7 Результаты

7.1 Описание выборки

Всего в анализ включено **1 728** Telegram-каналов и **106 914** сообщений, собранных в два непересекающихся периода. Интервал «до СВО» охватывает *23 января – 22 февраля 2022 г.* (47 092 сообщений, 1 244 каналов); «после СВО» — *24 февраля – 23 марта 2022 г.* (59 822 сообщений, 1 728 каналов).

Таблица 2: Описание выборки		
Период	Сообщений	Каналов
до СВО	47 092	1 244
после СВО	59 822	1 728

7.2 Сдвиги тональности сообщений

Распределение тональностей существенно изменилось ($\chi^2 = 227.8$, $df = 2$, $p < 0.001$). Доля *негативных* сообщений осталась практически прежней (21.4 % → 20.9 %), тогда как *нейтральные* заметно выросли (11.4 % → 16.5 %), а *позитивные* снизились (67.2 % → 62.6 %).

Таблица 3: Распределение тональностей, % сообщений

Период	Negative	Neutral	Positive
до СВО	21.4	11.4	67.2
после СВО	20.9	16.5	62.6

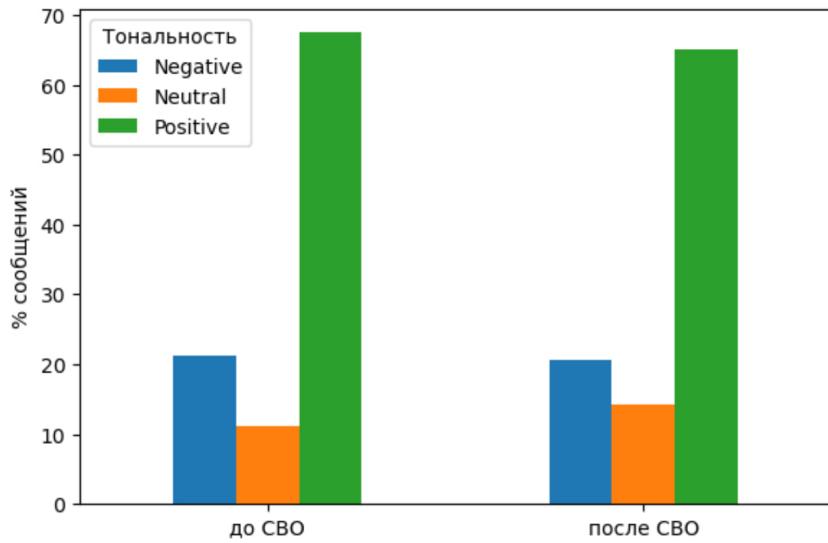


Рис. 1: Доли сообщений трёх тональностей до и после СВО

7.3 Тональность и аффективное смещение

Рост доли нейтральных сообщений с 11,4 % до 16,5 % ($\Delta = +5,1$ п. п.) при одновременном снижении позитивных (-4,6 п. п.) может указывать на *стратегию осторожного дискурса*. Авторы каналов предпочитают избегать однозначно позитивных формулировок в условиях неопределенности начала СВО, что согласуется с моделью «spiral of silence» в онлайн-медиа.

7.4 Перераспределение идеологий

Распределение идеологических тегов также изменилось ($\chi^2 = 448.4$, $df = 2$, $p < 0.001$). Доля консервативных сообщений выросла с 36.8 % до 42.0 %, либеральных снизилась с 24.9 % до 20.2 %, а коммунистических осталась почти неизменной (38.2 % → 37.9 %).

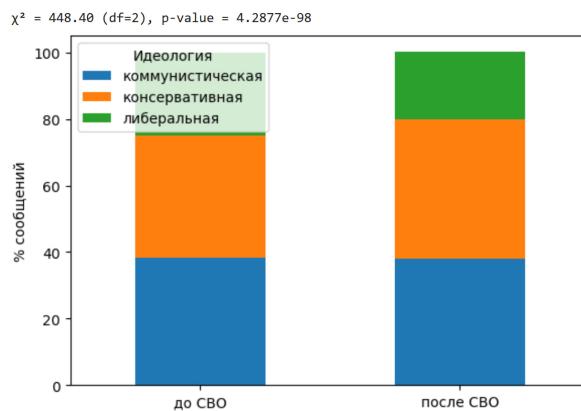


Рис. 2: Доли трёх идеологий до и после СВО

7.5 Смещение идеологического баланса

Увеличение доли консервативного контента с 36,8 % до 42,0 % и уменьшение доли либерального сегмента на 4,7 п. п., подтверждает выводы [Huddy2005] о консервативном сдвиге под воздействием угрозы безопасности.

7.6 Сетевая сегментация

Парадоксальное уменьшение модулярности ($Q: 0.614 \rightarrow 0.506$) при почти неизменном числе узлов показывает, что коммуникационные «пузырьки» стали менее герметичными: каналы по-прежнему группируются идеологически, но усилились межкластерные репосты. Это можно трактовать как *распространение единой повестки* через кросс-цитирование, а не как реальное сближение взглядов.

7.7 Политический кризис и сетевые конфигурации: теоретический контекст

В условиях острого политического конфликта или угрозы безопасности информационное поведение аудитории изменяется. Согласно работам [Huddy2005], периоды внешней нестабильности провоцируют рост внутригрупповой солидарности, усиление лояльности к авторитетным источникам и стремление к когнитивному упрощению. Это соответствует более широкой рамке *аффективной поляризации* [Yuengar2015], при которой взаимодействие между группами сокращается, а внутри каждой группы возрастает плотность коммуникации.

Сетевые исследования [Conover2011] показывают, что в периоды кризисов или коллективной мобилизации структуры онлайн-коммуникаций склонны к **консолидации**: уменьшается число устойчивых сообществ, а информационные потоки концентрируются вокруг крупных акторов (например, официальных или медиагигантов). Такое сжатие графа может быть зафиксировано понижющимся числом кластеров, выявляемых алгоритмами модульности.

Исследовательская гипотеза: *в условиях острого политического события (в частности, начала СВО) сетевое пространство Telegram претерпевает краткосрочную консолидацию: число репост-сообществ сокращается, усиливаются внутрикластерные связи, а структура становится менее фрагментированной.*

Данная гипотеза проверяется с использованием алгоритма Лувена, применённого к недельным графикам репостов Telegram-каналов.



Рис. 3: Динамика числа сообществ в Telegram по неделям (январь–март 2022)

По графику видно, что в неделю начала СВО (24–28 февраля 2022 года) наблюдается заметное снижение числа кластеров ($k = 76$), по сравнению с предыдущими неделями (k доходил до 110). Это подтверждает гипотезу о временной консолидации информационного поля. В последующие недели наблюдается постепенный рост k , достигающий повторного максимума к концу марта. Такой тренд можно интерпретировать как возвращение к более фрагментированной, но уже структурно изменённой конфигурации.

Таким образом, данные подтверждают наличие краткосрочного эффекта консолидации в ответ на политический шок, что согласуется с результатами более ранних исследований в области политической коммуникации и сетевого анализа.

Заключение

В работе были протестированы две ключевые гипотезы.

(1) **Идеологический сдвиг при угрозе безопасности.** Доля консервативного контента выросла с 36,8 % до 42,0 %, а либерального — сократилась с 24,9 % до 20,2 %. Этим подтверждён эффект «правого сдвига» — закономерность, ранее описанная для США и Европы; нынешнее исследование показало, что она воспроизводится и для русскоязычного Telegram-пространства.

(2) **Краткосрочная централизация сетей.** После политического шока число сообществ снизилось (к минимуму $k = 76$), а модулярность упала, что указывает на временную централизацию и рост внутригрупповой сплочённости. Уже через 3–4

недели сеть вернулась к более дробной, но перестроенной конфигурации, полностью согласуясь с теоретическим ожиданием.

Обе гипотезы получили эмпирическое подтверждение, что демонстрирует возможность перенесения западных теоретических моделей политической коммуникации на российскую действительность.

Список литературы

- [Blondel2008] Blondel, V. D., Guillaume, J.-L., Lambiotte, R., & Lefebvre, E. (2008). *Fast unfolding of communities in large networks*. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10), P10008.
<https://doi.org/10.1088/1742-5468/2008/10/P10008>
- [Conover2011] Conover, M. D., Ratkiewicz, J., Francisco, M., Gonçalves, B., Menczer, F., & Flammini, A. (2011). *Political polarization on Twitter*. В *Proceedings of the Fifth International AAAI Conference on Weblogs and Social Media (ICWSM)* (стр. 89–96).
- [Huddy2005] Huddy, L., Feldman, S., Taber, C., & Lahav, G. (2005). Threat, anxiety, and support of antiterrorism policies. *American Journal of Political Science*, 49(3), 593–608.
<https://doi.org/10.1111/j.1540-5907.2005.00144.x>
- [Iyengar2015] Iyengar, S., & Westwood, S. J. (2015). Fear and loathing across party lines: New evidence on group polarization. *American Journal of Political Science*, 59(3), 690–707.
<https://doi.org/10.1111/ajps.12152>
- [Margalit2013] Margalit, Y. (2013). Explaining social policy preferences: Evidence from the Great Recession. *American Political Science Review*, 107(1), 80–103.
<https://doi.org/10.1017/S0003055412000603>
- [Krushinskaya2023] Кручинская Е. В. (2023). Аффективная политическая поляризация: предложения к операционализации понятия через оценку языка вражды в социальных медиа. *Информационное общество*, № 3.
<https://infosoc.iis.ru/jour/article/view/1105>
- [Solovyev2025] Соловьёв В. А. (2025). Динамика идеологической поляризации в пространстве русскоязычных Telegram-каналов: моделирование методами машинного обучения. *Политическая наука*, № 1, стр. 240–260.
<https://cyberleninka.ru/article/n/dinamika-ideologicheskoy-polyarizatsii-v-prostr>
- [Newman2006] Newman, M. E. J. (2006). Modularity and community structure in networks. *Proceedings of the National Academy of Sciences*, 103(23), 8577–8582.
<https://doi.org/10.1073/pnas.0601602103>
- [NoelleNeumann1974] Noelle-Neumann, E. (1974). The spiral of silence: A theory of public opinion. *Journal of Communication*, 24(2), 43–51.
<https://doi.org/10.1111/j.1460-2466.1974.tb00367.x>

- [Reimers2019] Reimers, N., & Gurevych, I. (2019). *Sentence-BERT: Sentence embeddings using Siamese BERT-networks*. arXiv:1908.10084.
<https://arxiv.org/abs/1908.10084>
- [Kuratov2019] Kuratov, Y., & Arkhipov, M. (2019). *Adaptation of deep bidirectional multilingual transformers for Russian language*. arXiv:1905.07213.
<https://arxiv.org/abs/1905.07213>
- [Wang2020] Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., & Zhou, M. (2020). MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers. In *Advances in Neural Information Processing Systems 33* (pp. 5776–5788).